R과 redshift를 항해할 때 알아야할 상식사전(+협업)

https://mrchypark.github.io/redshift-with-r

[pdf버전] [문의하기] [의견 및 오류 신고]

스타누르기는 컨텐츠 제작자를 춤추게 합니다.

박찬엽

2018년 10월 19일

목차

목차

1. 발표자 소개
2. R과 함께 redshift 라는 DB를 항해해보자
    - RPostgres vs RPostgreSQL
    - redshift 에서 schema
3. 날짜/시간 자료형
    - timezone 문제
    - 날짜 더하기

🍃 협업을 위해

- writexl vs openxlsx
- googledrive
- sendgridr
- keyring

발표자 소개

박찬엽

- (현)코빗 재무팀 데이터 담당자
  - 재무DB 구축/관리 및 자동화
- (전)서울도시가스 선행연구팀 연구원
  - 챗봇 엔진 개발 및 서버 구축
- (전)2017년 패스트 캠퍼스 데이터 분석 R 강의
  - 데이터 분석을 위한 중급 R 프로그래밍
- N사 뉴스 크롤러 N2H4, D사 뉴스 크롤러 DNH4 관리자
  - ForkonLP 프로젝트

- **FACEBOOK**@mrchypark
- **GITHUB**@mrchypark

블로그를 운영하고 있습니다.

열심히 R 생태계에 기여하고 있습니다.

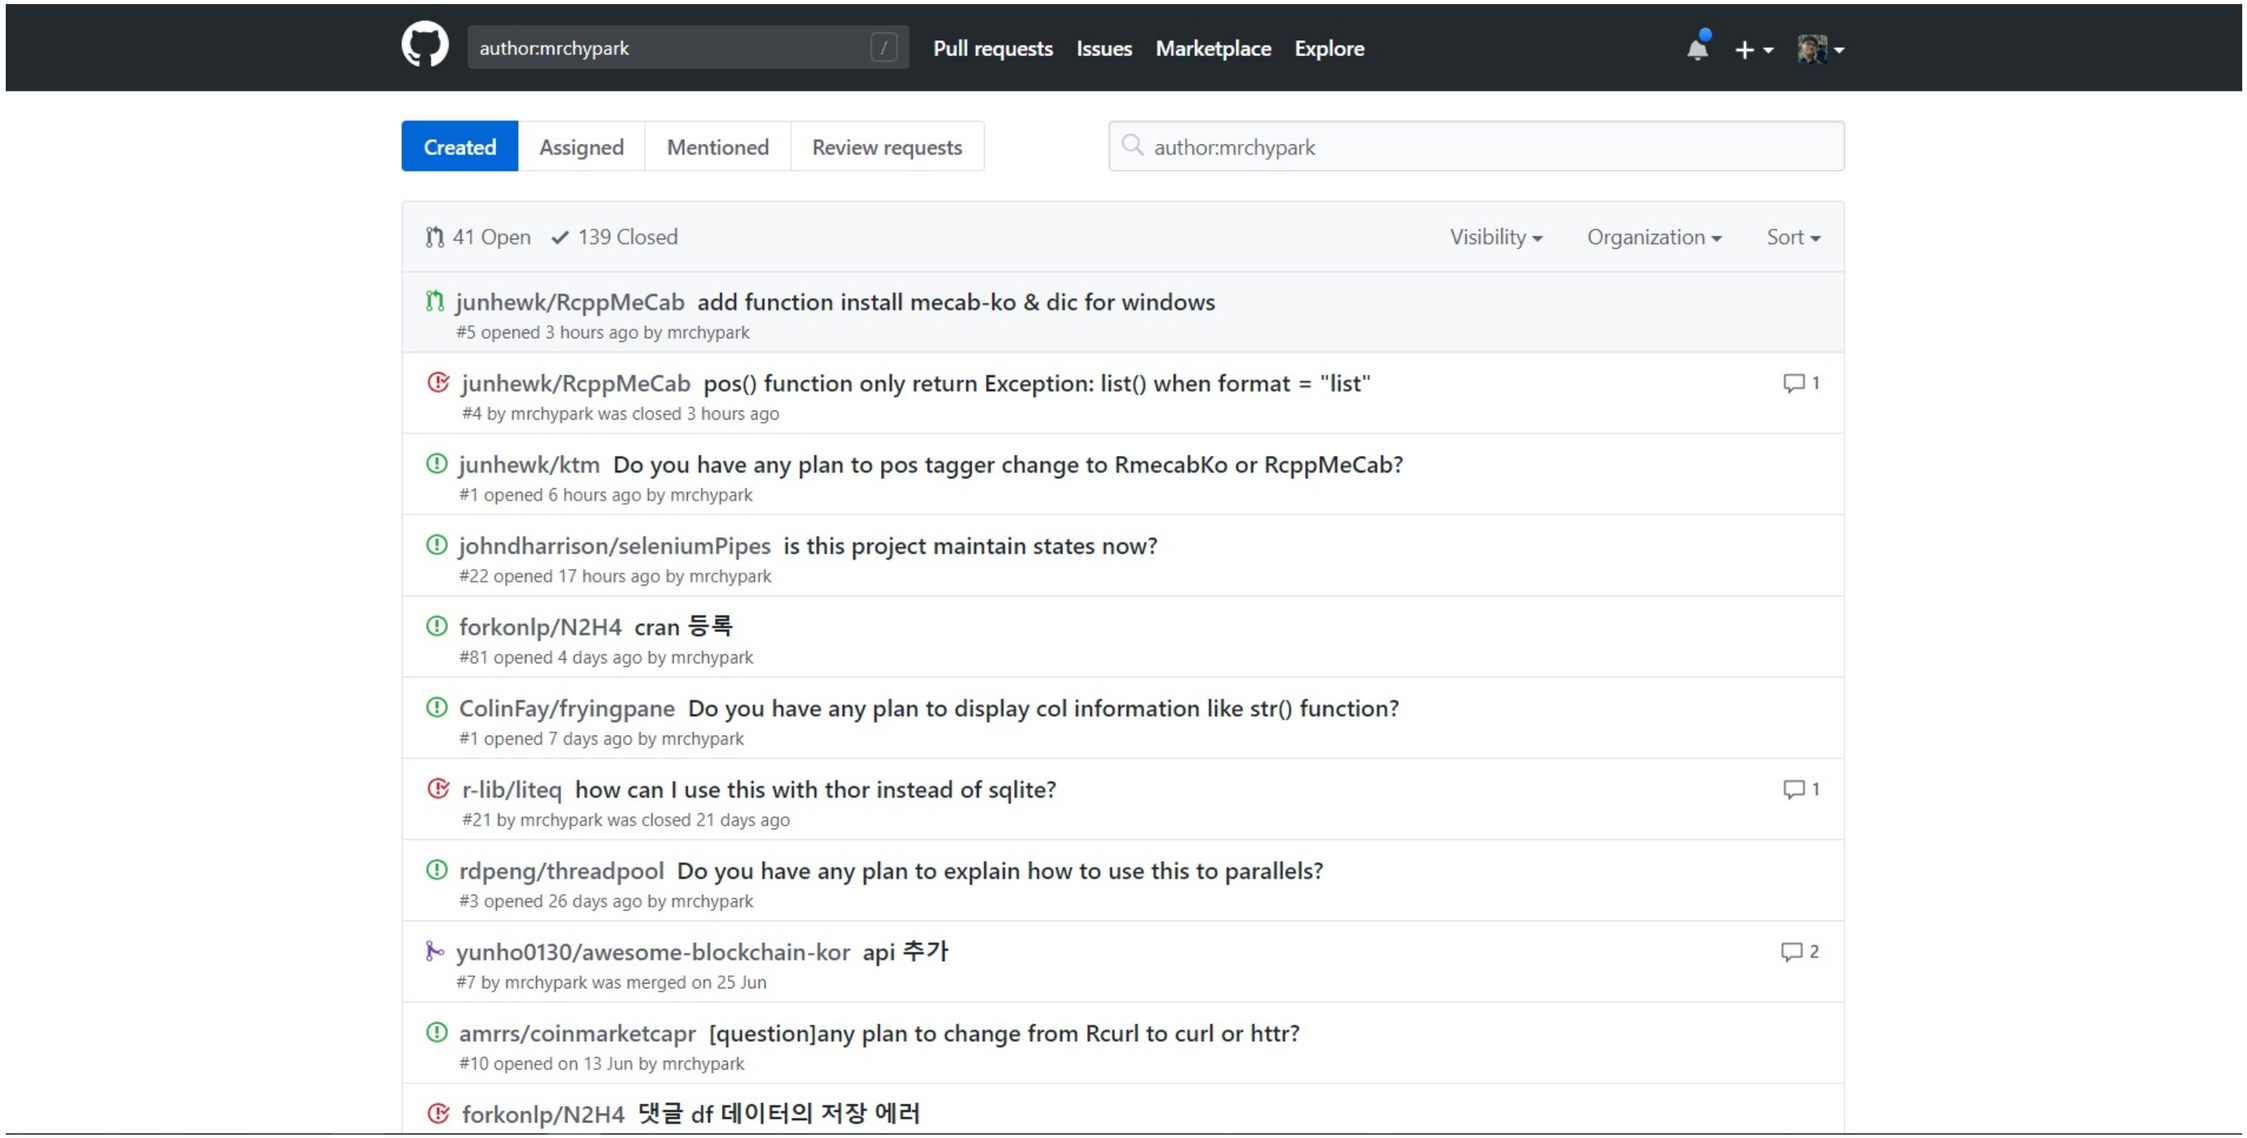

github 활동 많이 해주세요!

Git Awards | GitHub username | Search | Top users by city | Top users by country | Top users worldwide | About

Top R GitHub developers in South korea

R | South korea | Submit

	Username	Country rank	Stars
	forkonlp	1	105 ⭐
	mrchypark	2	102 ⭐
	cardiomoon	3	80 ⭐
	joelcarlson	4	51 ⭐
	youngwoos	5	43 ⭐
	keepcosmos	6	25 ⭐

forkonlp

- N2H4 : 댓글 수집이 가능한 네이버 뉴스 크롤러
- DNH4 : 댓글 수집이 가능한 다음 뉴스 크롤러
- presidentSpeechKr : 대통령 연설문
- stdkor : 표준국어대사전 텍스트 자료

개인

- sendgridr : 메일 전송 서비스 sendgrid api 패키지
- ubci : 업비트 거래소 인덱스&시세 데이터
- tqk : 한국 주식 데이터
- krlift : 한국 승강기 현황 데이터
- krlandprice : 한국 표준공시지가 데이터

잘 부탁드립니다.

코빗은 비트코인 거래소

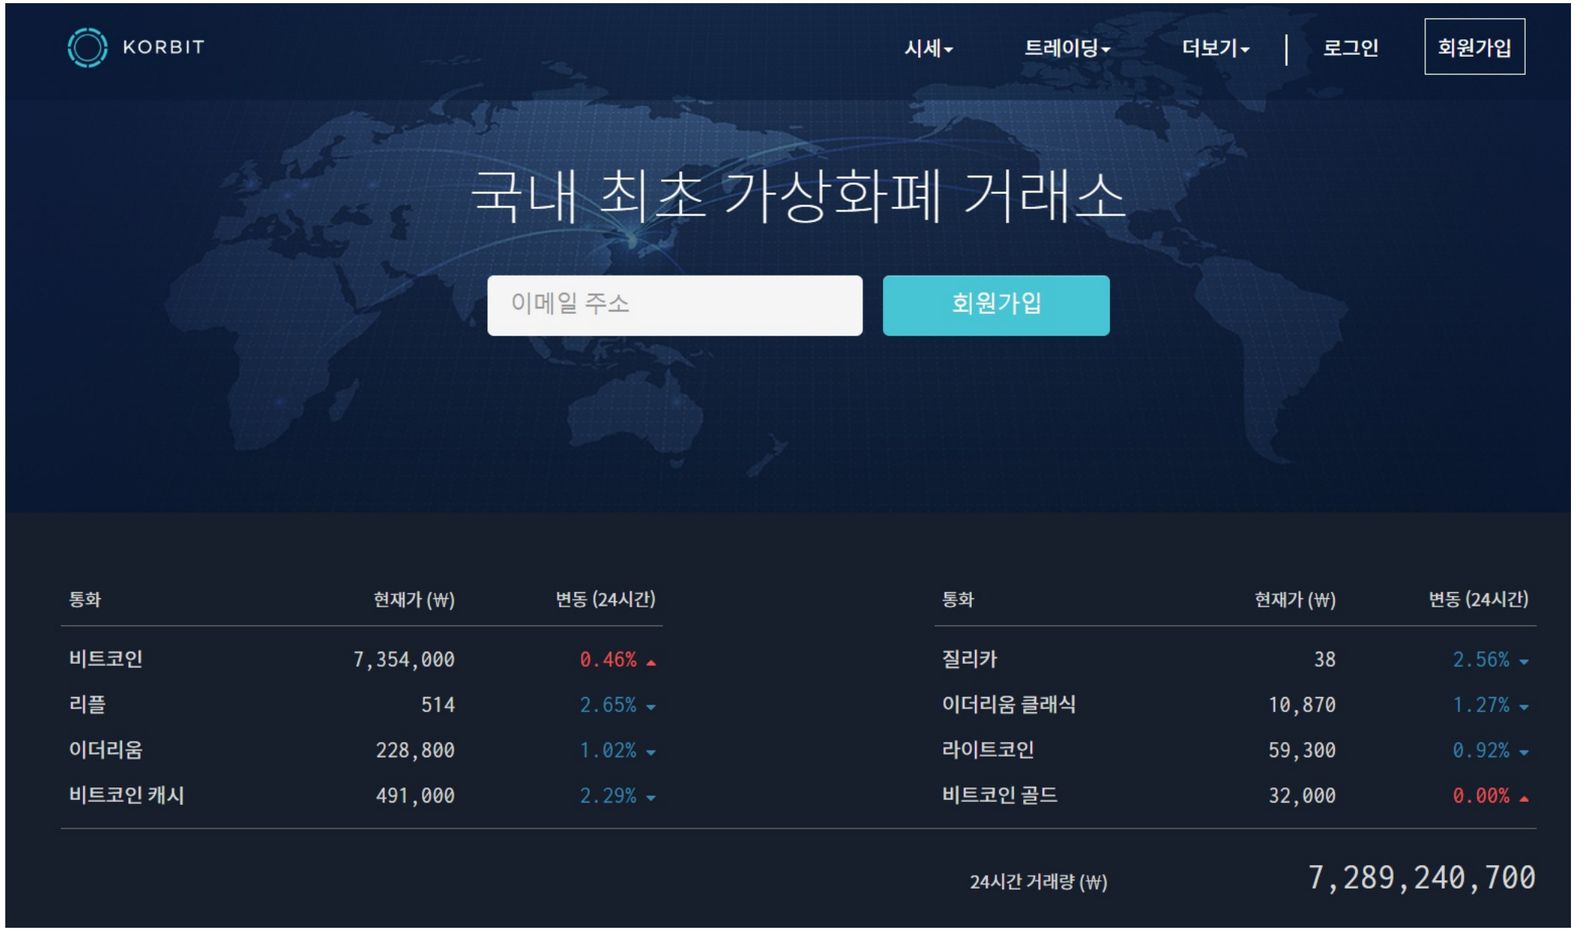
KORBIT
시세
트레이딩
더보기
로그인
회원가입
국내 최초 가상화폐 거래소
이메일 주소
회원가입
통화 현재가 (₩) 변동 (24시간)
비트코인 7,354,000 0.46%
리플 514 2.65%
이더리움 228,800 1.02%
비트코인 캐시 491,000 2.29%
통화 현재가 (₩) 변동 (24시간)
질리카 38 2.56%
이더리움 클래식 10,870 1.27%
라이트코인 59,300 0.92%
비트코인 골드 32,000 0.00%
24시간 거래량 (₩) 7,289,240,700

분석용 DW로 redshift를 사용하고 있음

R의 dplyr 로 db 다루는게 된다고 한거 같은데?!

dplyr의 가독성을 포기할 수 없었음

```
tbl(conn, 'flights') %>%
  group_by(tailnum) %>%
  summarise(count=n(),
            mean_distance = mean(distance, na.rm = TRUE),
            total_distance = sum(distance, na.rm = TRUE)) %>%
  filter(!is.na(tailnum))
```

```
## # Source:   lazy query [?? x 4]
## # Database: sqlite 3.22.0 []
##    tailnum count mean_distance total_distance
##    <chr>   <int>         <dbl>          <dbl>
##  1 D942DN      4           854.           3418
##  2 N0EGMQ    371           676.         250866
##  3 N10156    153           758.         115966
##  4 N102UW     48           536.          25722
##  5 N103US     46           535.          24619
##  6 N104UW     47           535.          25157
##  7 N10575    289           520.         150194
##  8 N105UW     45           525.          23618
##  9 N107US     41           529.          21677
## 10 N108UW     60           534.          32070
## # ... with more rows
```

걱정하지 마 미래의 나야, 훗!

연결할 수 있는가?

R ❤ Database

driver list (DBI supported)

- SQLite
- MySQL(+MariaDB)
- bigquery
- Oracle
- ...

+noDBI supported

- MongoDB
- Redis
- CouchDB
- Elasticsearch
- etcd
- ...

driver list (DBI supported)

- SQLite
- MySQL(+MariaDB)
- bigquery
- Oracle
- ...

+noDBI supported

- MongoDB
- Redis
- CouchDB
- Elasticsearch
- etcd
- ...

+ sergeant (with Apache Drill)

- HBase
- MapR-DB
- HDFS
- MapR-FS
- Amazon S3
- ...

+ JDBC & ODBC

aws의 공식 문서는 jdbc를 안내함

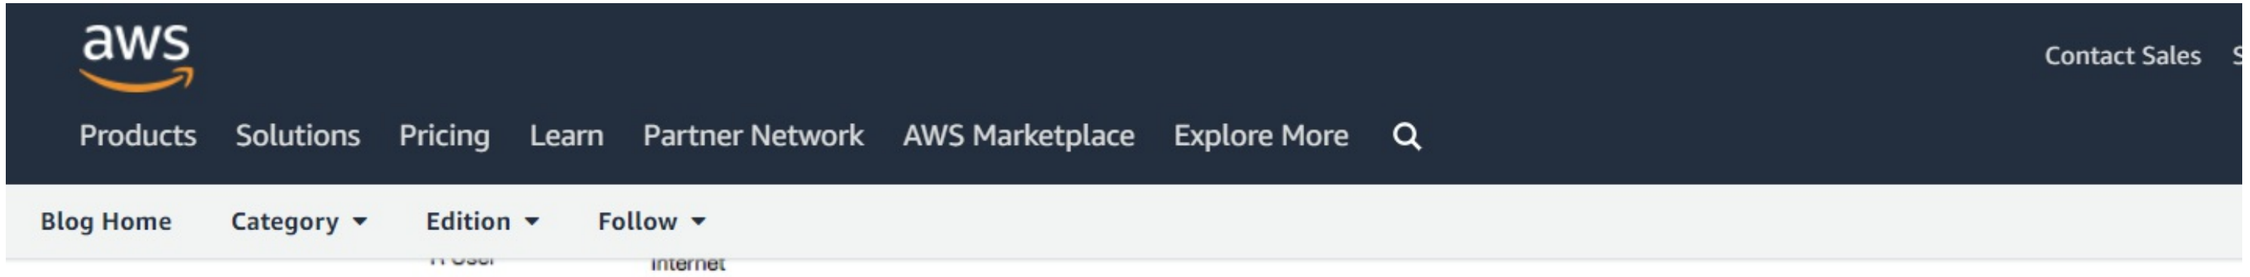

Connecting R to Amazon Redshift with RJDBC

As soon as you have an R session and the data loaded to Amazon Redshift, you can connect them. The recommended connection method is using a client application or tool that executes SQL statements through the PostgreSQL ODBC or JDBC drivers.

In R, you can install the *RJDBC* package to load the JDBC driver and send SQL queries to Amazon Redshift. This requires a matching JDBC driver. Choose the **latest** JDBC driver provided by AWS (Configure a JDBC Connection).

This driver is based on the PostgreSQL JDBC driver but optimized for performance and memory management.

```
install.packages("RJDBC")
library(RJDBC)

# download Amazon Redshift JDBC driver
download.file('http://s3.amazonaws.com/redshift-downloads/drivers/RedshiftJDBC41-1.1.9.1009.jar','

# connect to Amazon Redshift
```

jdbc 의 단점

1. java 설치
    - 현재 버전의 rJava는 경로 문제가 해결되었습니다.
2. 숫자와 문자로만 자료형 제공
    - 날짜, 논리형, 시간 등 모두 문자 자료형으로 제공
3. 정밀도가 떨어짐.
    - 예를 들어 9223372036854775807를 9223372036854775808로 리턴해줌

DBI

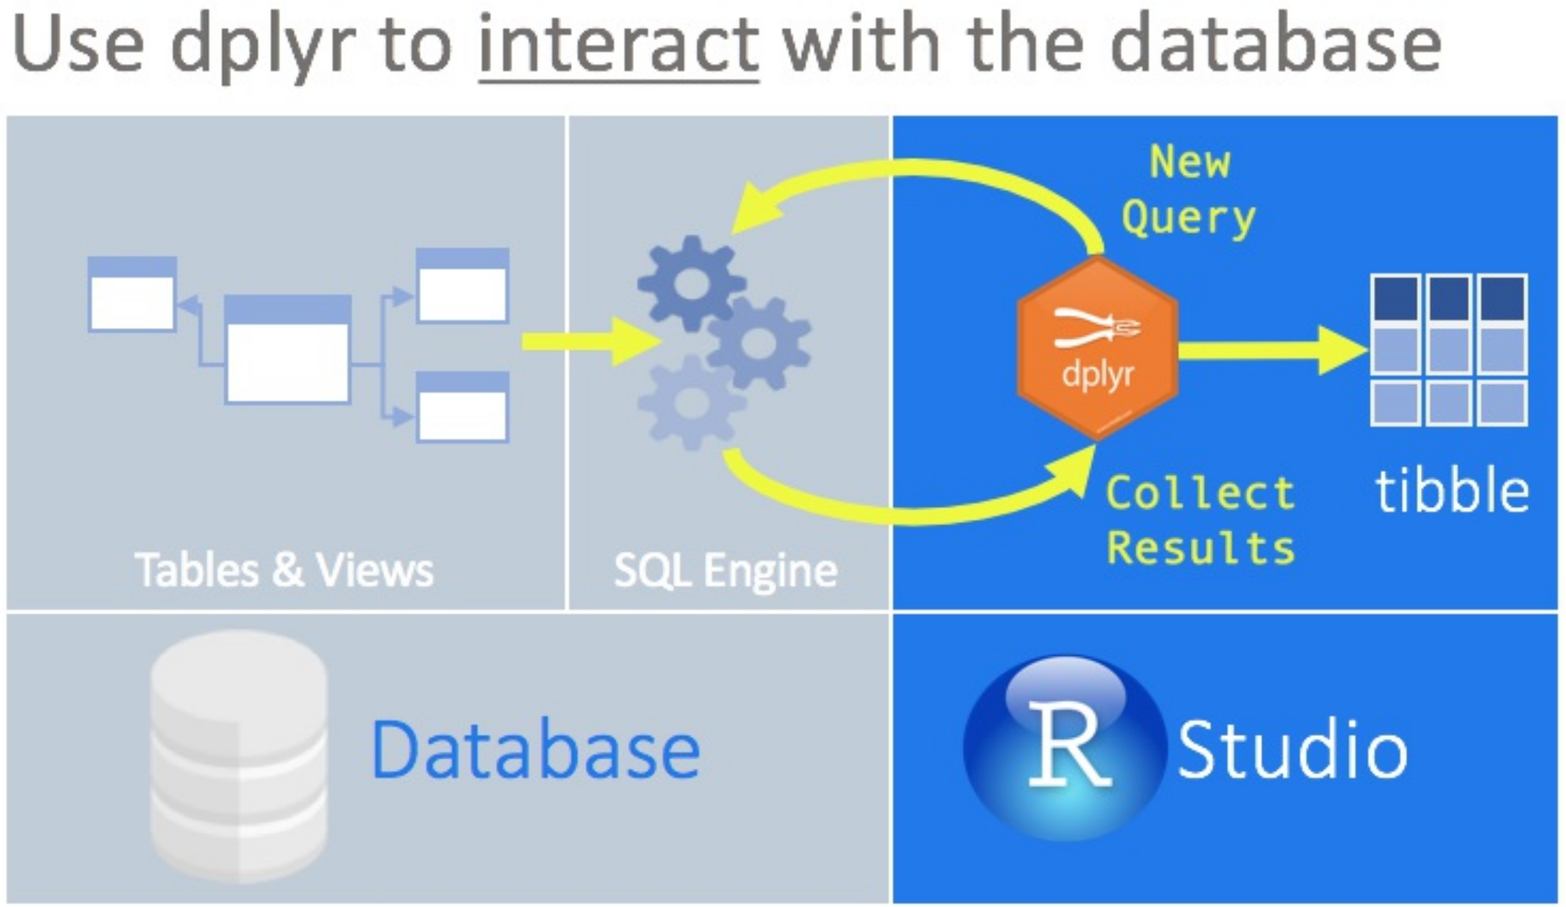
Use dplyr to interact with the database
Tables & Views
SQL Engine
New Query
dplyr
Collect Results
tibble
Database
R Studio

RPostgreSQL & RPostgres

RPostgreSQL

1. ssl 등 보안 연결 지원 미흡

RPostgreSQL

1. ssl 등 보안 연결 지원 미흡

회사에서 사용하기 어려움...

RPostgres

1. postgres 팀의 표준 라이브러리(libpq) 사용
2. DBI 패키지 관리 팀이 함께 지원 관리
3. 연결 풀 및 메모리 자동 관리

연결해 보자

```
library(DBI)
conn <- dbConnect(RPostgres::Postgres(), # 그대로 사용
                  host = host,           # redshift의 endpoint 주소
                  port = port,           # 사용하는 port redshift는 기본값이 5439
                  user = user,           # DB 계정(소위 ID)
                  password = password,   # 비밀 번호
                  dbname = dbname,       # 필수 아님. redshift에 기본 db가 표시됨
                  sslmode='require'      # 암호 연결 요구
                  )
```

연결 성공! 했지만

테이블이 없다?!

```
dbListTables(conn)
```

```
## character(0)
```

스키마를 통해 권한 관리

~~실제 스키마가 뭔지는 잘 모르겠지만~~ 폴더 같은 역할을 수행(postgres)

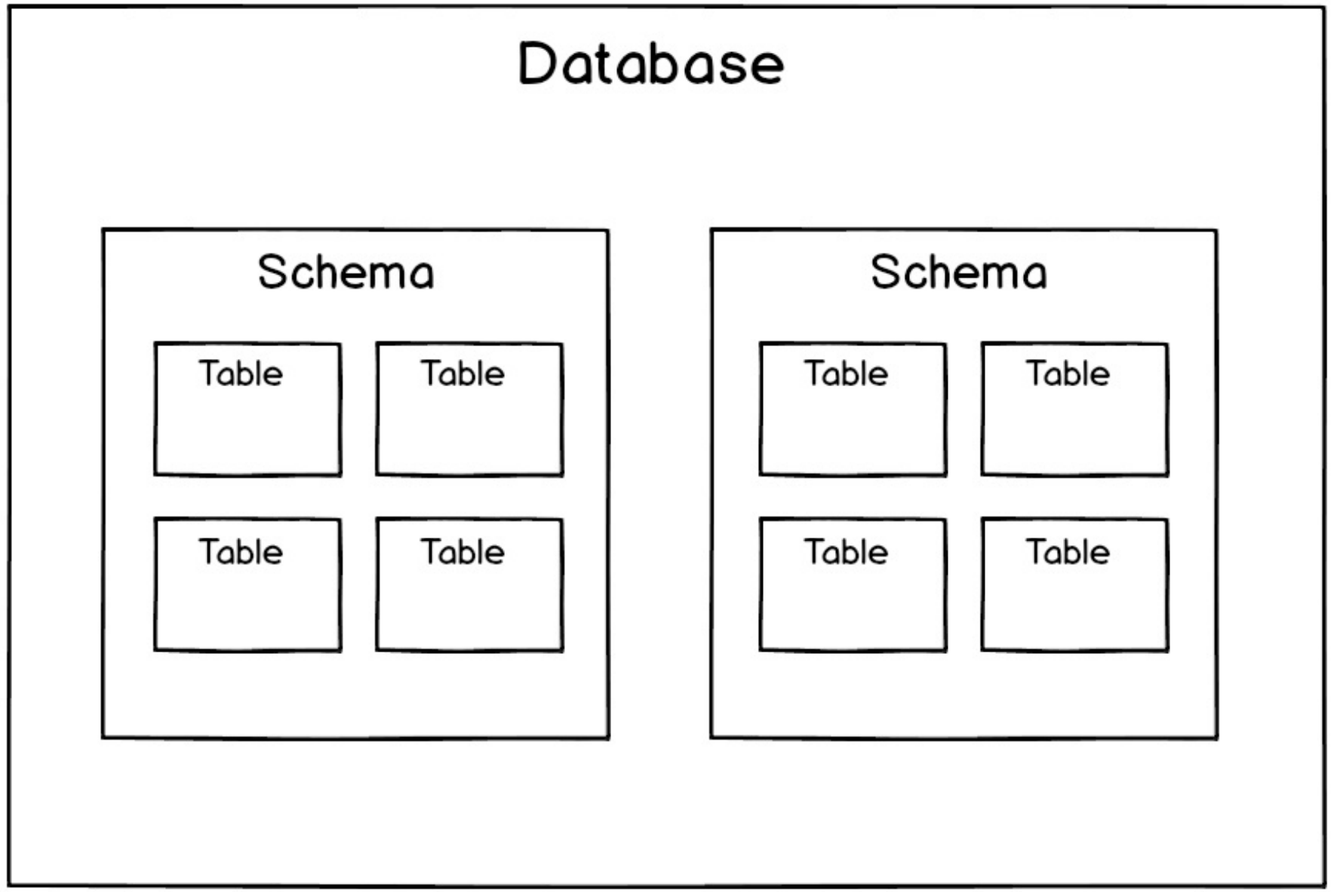

스키마 내의 테이블 리스트를 가져오는 법

postgres에서 스키마 내의 테이블을 보는 방법을 찾아보니 쿼리문이 있음

```
dbGetQuery("SELECT * FROM information_schema.tables WHERE table_schema = 'public'")
```

스키마 내의 테이블 리스트를 가져오는 법

postgres에서 스키마 내의 테이블을 보는 방법을 찾아보니 쿼리문이 있음

```
dbGetQuery("SELECT * FROM information_schema.tables WHERE table_schema = 'public'")
```

전부 R로 하려고 고집 부리지 않는다

redshift에서 스키마 내의 테이블 불러오기

테이블 명으로 dplyr의 tbl 형으로 찾을 수 없다고 출력

```
tbl(con, "table_name")
```

```
## Error in result_create(conn@ptr, statement) :
##   Failed to prepare query: ERROR:  relation "table_name" does not exist
```

redshift에서 스키마 내의 테이블 불러오기

테이블 명으로 dplyr의 tbl 형으로 찾을 수 없다고 출력

```
tbl(con, "table_name")
```

```
## Error in result_create(conn@ptr, statement) :
##   Failed to prepare query: ERROR:  relation "table_name" does not exist
```

schema.table_name 형태로 스키마를 선언해줘도 같은 문제 발생

```
tbl(con, "schema.table_name")
```

```
## Error in result_create(conn@ptr, statement) :
##   Failed to prepare query: ERROR:  relation "schema.table_name" does not exist
```

schema.table_name로 테이블 지정

`sql()` 함수를 이용해서 쿼리한 테이블을 연결해줘야 함.

```
tbl(con, sql("select * from schema.table_name"))
```

dbplyr 패키지

~~다른 좋은 함수가 많겠지만!~~ in_schema 명령어 지원

```
if (!requireNamespace("dbplyr")) install.packages("dbplyr")
library(dbplyr)
```

```
##
## Attaching package: 'dbplyr'

## The following objects are masked from 'package:dplyr':
##
##     ident, sql
```

```
tbl(con, in_schema("schema", "table_name"))
```

dplyr에서 유용한 함수

collect()

collect()는 DB에 전달하는 명령의 최종 결과를 R 객체로 가져오는 역할을 수행

```
tb_flights %>%
  group_by(carrier) %>%
  summarise(count = n())
```

```
# Source:   lazy query [?? x 2]
# Database: sqlite 3.22.0 [:memory:]
   carrier count
   <chr>   <int>
 1 9E      18460
 2 AA      32729
 3 AS        714
 4 B6      54635
 5 DL      48110
 6 EV      54173
 7 F9        685
 8 FL       3260
 9 HA        342
```

```
tb_flights %>%
  group_by(carrier) %>%
  summarise(count = n()) %>%
  collect()
```

```
## # A tibble: 16 x 2
##    carrier count
##    <chr>   <int>
##  1 9E      18460
##  2 AA      32729
##  3 AS        714
##  4 B6      54635
##  5 DL      48110
##  6 EV      54173
##  7 F9        685
##  8 FL       3260
##  9 HA        342
```

show_query()

show_query()는 dplyr로 구성된 함수의 연결이 query문으로 어떻게 변환되는지를 보여줌

```
copy_to(conn, planes, name = 'planes', temporary = FALSE)
tbl(conn, 'planes_distance') %>%
  inner_join(tbl(conn, 'planes'), by='tailnum') %>%
  arrange(desc(total_distance)) %>%
  select(total_distance, manufacturer, model) %>%
  show_query()
```

```
<SQL>
SELECT `total_distance`, `manufacturer`, `model`
FROM (SELECT *
FROM (SELECT `TBL_LEFT`.`tailnum` AS `tailnum`, `TBL_LEFT`.`count` AS `count`, `TBL_LEFT`.`mear
  FROM `planes_distance` AS `TBL_LEFT`
  INNER JOIN `planes` AS `TBL_RIGHT`
  ON (`TBL_LEFT`.`tailnum` = `TBL_RIGHT`.`tailnum`)
)
ORDER BY `total_distance` DESC)
```

이제 dplyr을 잘 사용하면 되는건가?

거래소는 24시간이 모자라

박찬엽

- (현)코빗 **재무팀** 데이터 담당자

- (전)서울도시가스 선행연구팀 연구원
  - 챗봇 엔진 개발 및 서버 구축
- (전)2017년 패스트 캠퍼스 데이터 분석 R 강의
  - 데이터 분석을 위한 중급 R 프로그래밍
- N사 뉴스 크롤러 N2H4, D사 뉴스 크롤러 DNH4 관리자
  - ForkonLP 프로젝트

- **FACEBOOK**@mrchypark
- **GITHUB**@mrchypark

재무팀의 시간

일단위(daily) 데이터 처리

시간이 매우 중요하다.

1. 여러 테이블들의 관계에서 기준 시간을 정해야 함.
    - 수많은 created_at과 updated_at 사이에서 찾아야...
2. timezone 확인
    - 외국인 등 이유로 UTC(협정 세계시) 사용
3. 거래 취소 등이 나중에 발생하기도 함
    - 18일에 확인한 17일 값과 19일에 확인한 17일 값이 다를 수 있음

날짜/시간 자료형이 어려워서

year, month, day 같이 컬럼별로 쪼개 두기도 함

```
library(nycflights13)
flights
```

```
## # A tibble: 336,776 x 19
##      year month   day dep_time sched_dep_time dep_delay arr_time
##    <int> <int> <int>    <int>          <int>     <dbl>    <int>
##  1  2013     1     1      517            515         2      830
##  2  2013     1     1      533            529         4      850
##  3  2013     1     1      542            540         2      923
##  4  2013     1     1      544            545        -1     1004
##  5  2013     1     1      554            600        -6      812
##  6  2013     1     1      554            558        -4      740
##  7  2013     1     1      555            600        -5      913
##  8  2013     1     1      557            600        -3      709
##  9  2013     1     1      557            600        -3      838
## 10  2013     1     1      558            600        -2      753
## # ... with 336,766 more rows, and 12 more variables: sched_arr_time <int>,
## #   arr_delay <dbl>, carrier <chr>, flight <int>, tailnum <chr>,
## #   origin <chr>, dest <chr>, air_time <dbl>, distance <dbl>, hour <dbl>,
## #   minute <dbl>, time_hour <dttm>
```

날짜/시간 자료형

잘 만들어진 시스템을 **잘** 사용해보자

timezone

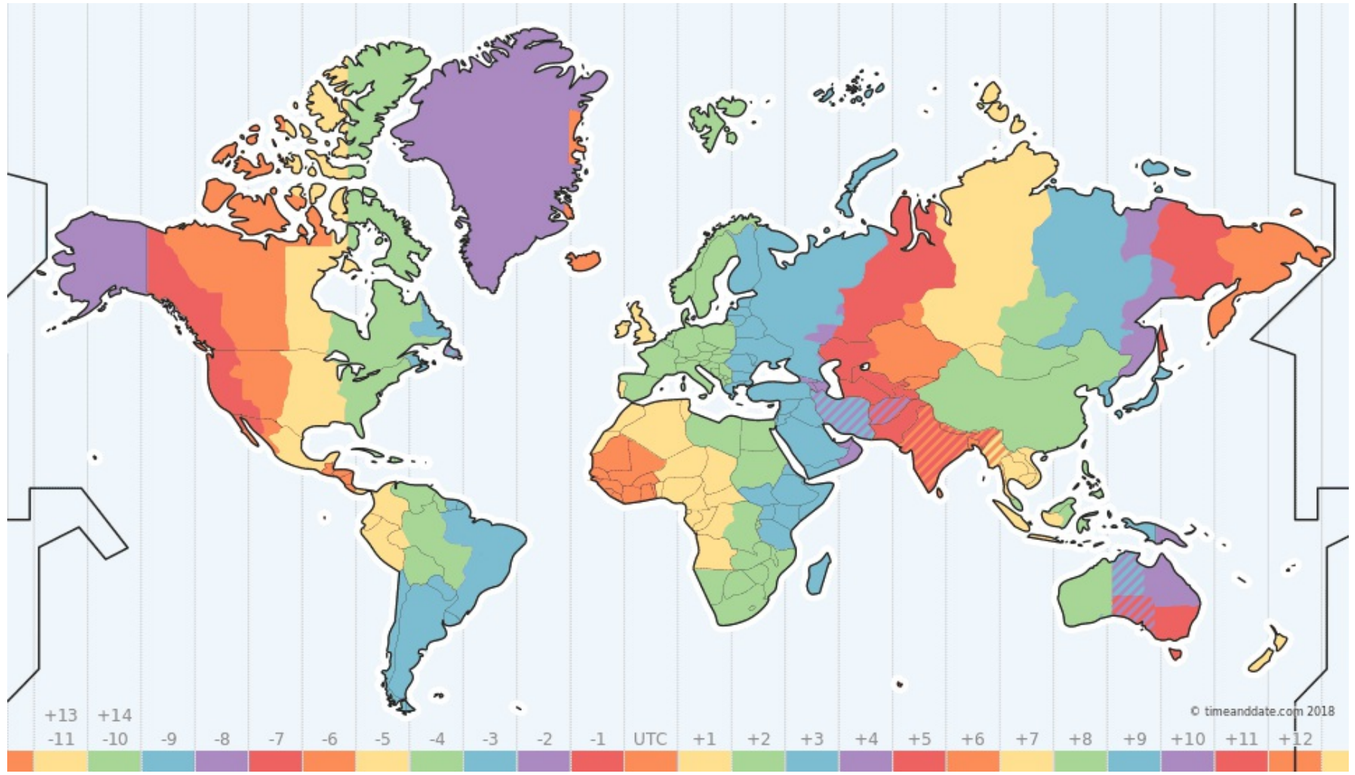
+13 -11
+14 -10
-9
-8
-7
-6
-5
-4
-3
-2
-1
UTC
+1
+2
+3
+4
+5
+6
+7
+8
+9
+10
+11
+12
© timeanddate.com 2018

한국은?

한국은?

Asia/Seoul(KST)

한국은?

Asia/Seoul(KST)

UTC(협정 세계시) + 9시간

Timezones in base R

UTC 그런거 없음

```
x <- "2018-01-01 06:00:00 UTC"
as.POSIXct(x)
```

```
## [1] "2018-01-01 06:00:00 KST"
```

```
as.POSIXct(x, tz = "Asia/Seoul")
```

```
## [1] "2018-01-01 06:00:00 KST"
```

```
Sys.timezone()
```

```
## [1] "Asia/Seoul"
```

```
Sys.time()
```

```
## [1] "2018-10-19 08:11:31 KST"
```

redshift는 UTC가 기본

postgres로 실습 환경 구성

```
library(DBI)
library(dplyr)
library(tibble)
library(lubridate)

con <- dbConnect(RPostgres::Postgres(),
                 host = '192.168.99.100',
                 port = 5432,
                 user = 'postgres',
                 password = '1q2w3e')

dtdata <- as.character(Sys.time()+sample(1:1000000,10))
dtdata <- tibble(time = dtdata) %>%
  mutate(time = as_datetime(time)) # lubridate::as_datetime() UTC 시간을 만들어 줌

copy_to(con, dtdata, overwrite =T)
dbListTables(con)
```

```
## [1] "dtdata"
```

as.Date 함수의 역습

```
tbl(con, "dtdata") %>%
  mutate(add = time %+ interval% '9 hours') %>%
  collect() %>%
  mutate(date = as.Date(time),
         datez = as.Date(time, tz ="Asia/Seoul"),
         add9 = as.Date(add),
         add9z = as.Date(add, tz ="Asia/Seoul"))
```

```
## # A tibble: 10 x 6
##    time                add                 date       datez      add9
##    <dttm>              <dttm>              <date>     <date>     <date>
##  1 2018-10-25 05:37:35 2018-10-25 14:37:35 2018-10-24 2018-10-25 2018-10-25
##  2 2018-10-26 20:59:24 2018-10-27 05:59:24 2018-10-26 2018-10-26 2018-10-26
##  3 2018-10-20 15:53:53 2018-10-21 00:53:53 2018-10-20 2018-10-20 2018-10-20
##  4 2018-10-26 11:35:50 2018-10-26 20:35:50 2018-10-26 2018-10-26 2018-10-26
##  5 2018-10-21 11:20:45 2018-10-21 20:20:45 2018-10-21 2018-10-21 2018-10-21
##  6 2018-10-22 09:01:31 2018-10-22 18:01:31 2018-10-22 2018-10-22 2018-10-22
##  7 2018-10-21 18:22:48 2018-10-22 03:22:48 2018-10-21 2018-10-21 2018-10-21
##  8 2018-10-28 17:02:17 2018-10-29 02:02:17 2018-10-28 2018-10-28 2018-10-28
##  9 2018-10-23 21:44:18 2018-10-24 06:44:18 2018-10-23 2018-10-23 2018-10-23
## 10 2018-10-23 21:55:16 2018-10-24 06:55:16 2018-10-23 2018-10-23 2018-10-23
## # ... with 1 more variable: add9z <date>
```

헷갈리기 딱 좋음

1. `as.Date()` 함수가 알아서 UTC(?)로 되돌려 놓음.
    - 기본 R에서의 동작과 다름
2. `time %+ interval% '9 hours'` 같은 DB쪽 문법을 사용해야 함.
    - `time + hour(9)` 같은거 알아서 바꿔주지 않음 ~~ㅠㅠ~~
    - dplyr::mutate의 소스가 db_con 일 경우 글자 수준으로 sql 문에 전달
    - redshift는 `convert_timezone()` 함수를 지원함
    - `convert_timezone(time, "kst")` 같은 문법이 가능함

느낀 점

- **역시 공짜 점심은 없다**
- 어느 정도 각 DB 특성에 맞는 지식을 알고 있어야
- 날짜/시간 자료형은 어디서나 문제니 꼭 UTC 기준인지 확인 필요
- timezone 단위로 단위로 처리하는 것이 추상화된 해결책
- 다행히 인코딩 문제는 익숙한데... UTF-8을 확인하는 것이 중요 포인트

협업을 위한 패키지들

csv 대신 엑셀로 저장하기 - writexl

```
library(openxlsx)
library(writexl)
```

```
library(microbenchmark)
library(nycflights13)
microbenchmark(
  writexl = writexl::write_xlsx(flights, tempfile()),
  openxlsx = openxlsx::write.xlsx(flights, tempfile()),
  times = 3
)
```

```
## Unit: seconds
##       expr       min        lq      mean    median        uq       max neval
##    writexl  8.884712  8.904431  9.103419  8.965643  9.041565  9.720743     5
##   openxlsx 17.166818 18.072527 19.171003 18.669805 18.756661 23.189206     5
```

```
writexl::write_xlsx(flights, tmp1 <- tempfile())
file.info(tmp1)$size
## 29157282
openxlsx::write.xlsx(flights, tmp2 <- tempfile())
file.info(tmp2)$size
## 35962067
```

구글 드라이브

엑셀 파일 업로드

```
library(googledrive)
drive_upload(media = "what_you_want_to_upload_file",
             name = "name_of_upload_file",
             path = as_id("where_to_upload"))
```

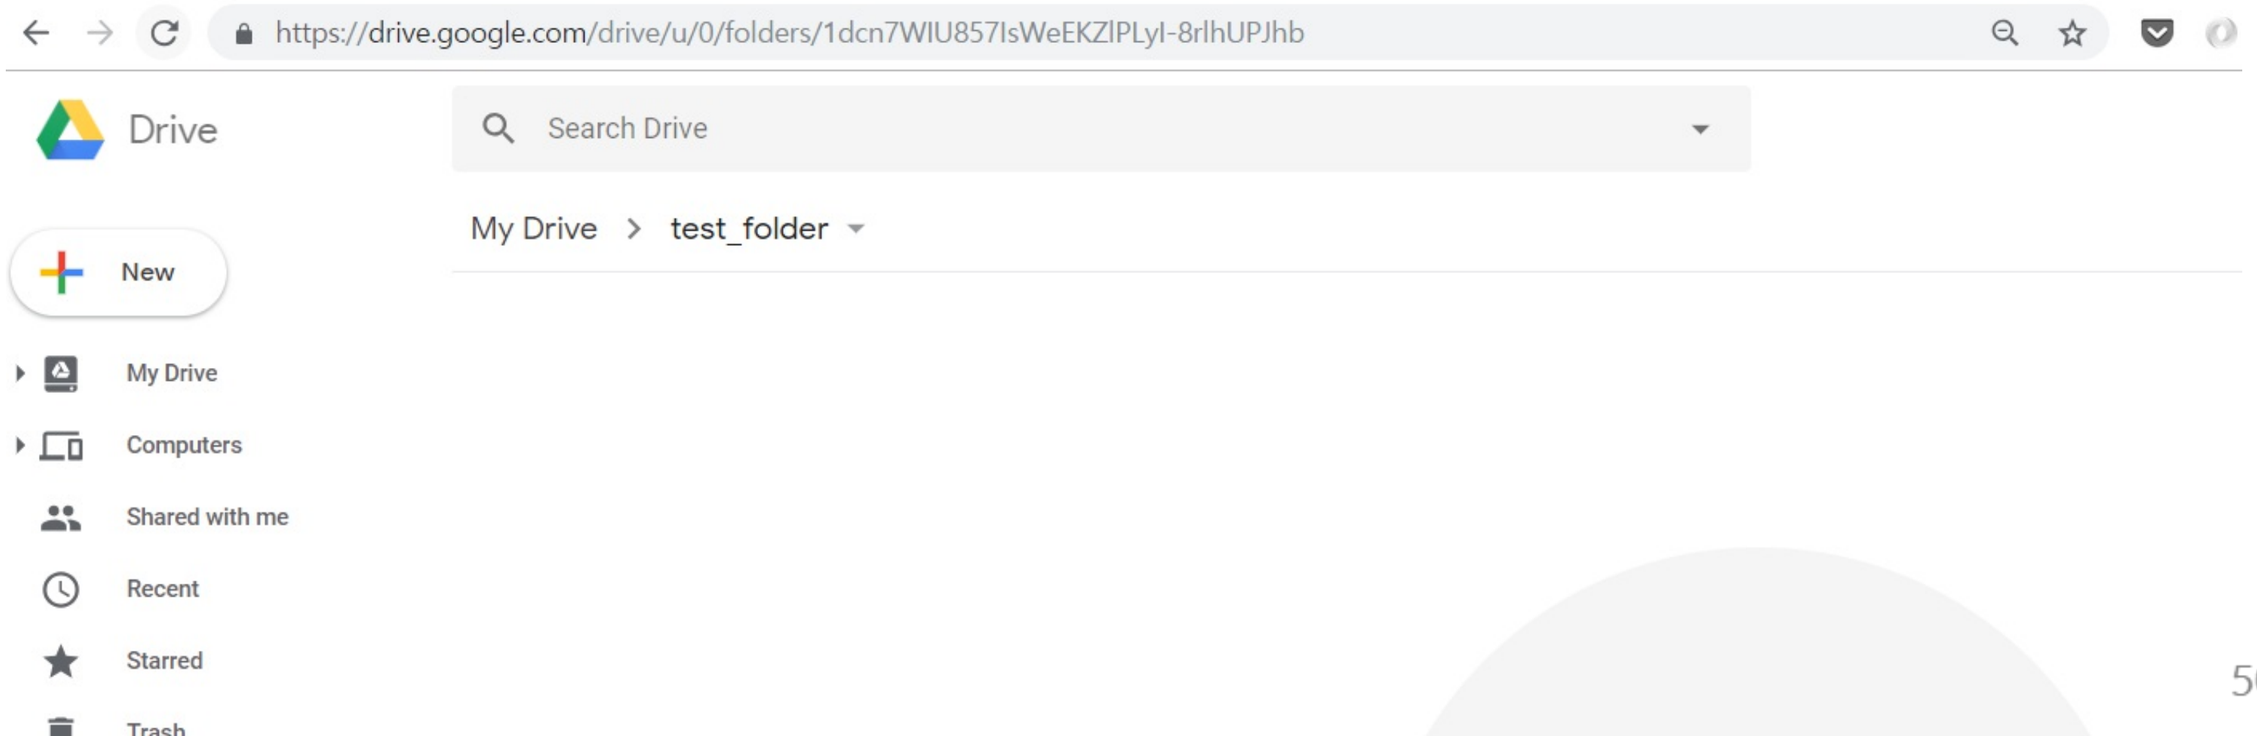

메일 보내기

rmd로 작성한 보고서 전송

구글에서 이미지를 제거해서 임시로 html을 첨부하는 형태로 우회중

```
mail() %>%
  from("your@mail.com") %>%
  to("where@togo.com") %>%
  subject("mail title") %>%
  content("mail body") %>%
  attachments("what_you_want_to_upload_file") %>%
  send()
```

보안을 위해 keyring

windows의 자격증명관리자, mac의 Keychain 을 이용해 비밀 번호 등을 암호화 저정후 활용

```
keyring::key_set("key-name-to-use")
con <- dbConnect(RPostgres::Postgres(),
                 host = '192.168.99.100',
                 port = 5432,
                 user = 'postgres',
                 password = keyring::key_get("key-name-to-use"))
```

깃헙등에 잘못 올릴 일이 없음

Q & A

Q & A

감사합니다